

Prueba - Modelo predictivo en Apache Spark MLlib

En este desafío final aplicaremos todo lo aprendido durante el módulo para construir un modelo predictivo funcional utilizando la biblioteca MLlib de Apache Spark. Deberás preparar los datos, seleccionar y entrenar un modelo supervisado, evaluarlo utilizando métricas apropiadas y justificar tus decisiones en términos técnicos y estratégicos.

Este trabajo consolida la progresión de los desafíos anteriores: desde la caracterización del problema y la propuesta inicial (Unidad 1), pasando por la limpieza y transformación con RDDs (Unidad 2), hasta el entrenamiento efectivo de un modelo de Machine Learning.

Lee todo el documento antes de comenzar el desarrollo **grupal**, para asegurarte de tener el máximo de puntaje y enfocar bien los esfuerzos.

// Tiempo asociado: 2 horas cronológicas

Descripción

En la unidad anterior preparaste un dataset con transacciones simuladas de ventas, incluyendo limpieza y transformación de los datos. Ahora, el área de operaciones quiere anticipar si una venta corresponde a una situación anómala (ej. errores de stock, transacciones atípicas, horarios inusuales).

Tu tarea será construir un modelo de clasificación binaria que prediga la probabilidad de que una transacción sea considerada como riesgosa, utilizando el entorno distribuido de Spark MLlib y técnicas básicas de preprocesamiento y modelado.

Requerimientos

1. Preparar el dataset para entrenamiento del modelo

Utilizando el dataset apoyo prueba - ventas_simuladas.csv, debes:

- Añadir una columna label binaria simulada (1: transacción riesgosa, 0: normal). Puedes asignarla aleatoriamente o con base en una regla simple (ej: monto_total > 7000 y venta en madrugada).
- Aplicar StringIndexer y VectorAssembler para preparar las columnas en el formato requerido por MLlib: una columna features y una columna label.



Entrega esperada: código comentado en PySpark + evidencia del DataFrame final con columnas features y label.
(2 puntos)

2. Entrenar un modelo supervisado de clasificación con MLlib

Entrena un modelo de clasificación binaria utilizando uno de los siguientes algoritmos de MLlib:

- LogisticRegression
- RandomForestClassifier
- DecisionTreeClassifier

Debes:

- Dividir el dataset en entrenamiento y prueba (randomSplit).
- Entrenar el modelo.
- Generar predicciones sobre los datos de prueba.



Entrega esperada: script en PySpark con todo el flujo de entrenamiento y predicción + tabla de predicciones con las columnas: label, prediction, probability.
(4 puntos)

3. Evaluar el modelo y justificar decisiones técnicas

Evalúa el desempeño del modelo utilizando al menos dos métricas de clasificación:

- accuracy
- areaUnderROC o F1-score

Además, justifica por qué elegiste ese modelo, qué resultados obtuviste y cómo podrías mejorarlo en una versión futura (ej: validación cruzada, selección de variables, ajuste de hiperparámetros).



Entrega esperada: salida de métricas + texto justificativo (máx. 200 palabras) en el mismo notebook o documento PDF.
(4 puntos)



¡Mucho éxito!

Consideraciones y recomendaciones

- Puedes trabajar en Databricks, Jupyter o Google Colab con PySpark configurado.
- Asegúrate de usar Pipeline si implementas múltiples etapas de transformación.
- Usa `.cache()` si el dataset es grande para mejorar rendimiento.